

Relación entre presupuesto, popularidad y valoración cinematográfica con los ingresos en taquilla mediante técnicas de análisis exploratorio de datos

Juan Diego Muñetón Herrera
Ingeniería de Sistemas
diego.muneton@udea.edu.co

Palabras Clave: Ciencia de datos, análisis exploratorio de datos, taquilla cinematográfica, transformación de variables, detección de outliers.

Resumen

El presente estudio analiza la relación entre el presupuesto, la popularidad y las valoraciones de las películas con sus ingresos en taquilla mediante técnicas de ciencia de datos y análisis exploratorio. Para ello, se utilizó un conjunto de datos compuesto inicialmente por 438483 registros provenientes de kaggle, los cuales fueron sometidos a procesos de limpieza, filtrado y transformación, obteniendo finalmente 9392 películas con información financiera válida. La metodología incluyó análisis univariado, bivariado y multivariado, detección de valores atípicos mediante IQR, Z-Score y K-Means, así como transformaciones estadísticas como Log, Box-Cox y Yeo-Johnson para reducir la asimetría de las variables financieras. Los resultados evidenciaron una fuerte relación positiva entre el presupuesto y los ingresos en taquilla, mientras que la popularidad mostró una influencia moderada y las valoraciones presentaron una relación débil con el desempeño financiero. Además, las transformaciones aplicadas mejoraron significativamente la distribución de los datos y facilitaron la identificación de patrones y anomalías. Se concluye que el presupuesto constituye el factor más asociado al éxito financiero de una película, aunque existen comportamientos atípicos que reflejan la complejidad del mercado cinematográfico.

1. Introducción

La industria cinematográfica representa uno de los sectores de entretenimiento con mayor impacto económico y cultural a nivel mundial. El éxito financiero de una película depende de múltiples factores relacionados tanto con la producción como con la recepción del público, entre ellos el presupuesto destinado a su desarrollo, la popularidad alcanzada en medios digitales y las valoraciones otorgadas por los espectadores y la crítica especializada. A partir de este contexto, surge la pregunta *¿Cómo se relacionan el presupuesto, la popularidad y las valoraciones de las películas con sus ingresos en taquilla?*

Actualmente, plataformas como Internet Movie Database (IMDb) y The Movie Database (TMDb) almacenan grandes volúmenes de información relacionada con películas, incluyendo métricas financieras, niveles de popularidad, valoraciones de usuarios y características de producción. El aprovechamiento de estos datos mediante técnicas de ciencia de datos permite identificar relaciones relevantes entre variables y detectar comportamientos atípicos difíciles de observar mediante análisis tradicionales.

Este proyecto tiene como objetivo analizar la relación existente entre el presupuesto, la popularidad y las valoraciones de las películas con sus ingresos en taquilla, aplicando técnicas de análisis exploratorio de datos, transformación de variables y detección de valores atípicos. Para ello, se desarrolló un proceso metodológico que incluyó limpieza y preparación de datos, análisis estadístico descriptivo, evaluación de correlaciones, escalamiento y normalización de variables, así como métodos estadísticos y de aprendizaje automático para la identificación de anomalías.

2. Metodología

Para el desarrollo del proyecto se utilizó un conjunto de datos cinematográficos integrado a partir de información proveniente de plataformas especializadas como Internet Movie Database (IMDb) y The Movie Database (TMDb). El dataset original contenía 438483 registros y 29 variables relacionadas con aspectos financieros, técnicos y descriptivos de películas, incluyendo presupuesto, ingresos en taquilla, popularidad, duración, valoraciones de usuarios, géneros y compañías productoras.

Las variables analizadas incluyeron tanto datos numéricos como categóricos y textuales. Entre las variables principales utilizadas en el estudio se encuentran:

- **budget:** presupuesto de producción de la película.
- **revenue:** ingresos obtenidos en taquilla.
- **popularity:** índice de popularidad calculado por la plataforma.
- **vote_average y averageRating:** valoraciones promedio de usuarios.

Debido a la existencia de registros incompletos o inconsistentes, se realizó un proceso de filtrado y limpieza que permitió conservar únicamente películas con valores válidos en las

variables financieras principales. Como resultado, el conjunto de datos final quedó conformado por 9394 películas.

2.1. Proceso de limpieza y preparación de datos

Inicialmente se realizó un análisis general de calidad de datos para identificar valores faltantes, registros inconsistentes y posibles anomalías. Posteriormente, se aplicaron los siguientes criterios de limpieza:

- Eliminación de películas con presupuesto (budget) menor a 1000 dólares.
- Eliminación de películas con ingresos (revenue) menor a 1000 dólares.
- Filtrado de películas con duración menor a 60 minutos para evitar registros atípicos asociados a cortometrajes o inconsistencias.

Adicionalmente, se verificó la existencia de registros duplicados y se realizó una evaluación de valores faltantes sobre las variables del conjunto de datos.

2.2. Técnicas de análisis exploratorio de datos

El análisis exploratorio de datos (EDA) se desarrolló mediante técnicas univariadas, bivariadas y multivariadas con el objetivo de identificar patrones, distribuciones y relaciones entre variables.

2.2.1 Análisis univariado

Se utilizaron:

- histogramas
- funciones de densidad
- boxplots
- medidas descriptivas

Entre las medidas calculadas se incluyeron:

- media
- mediana
- desviación estándar
- rango
- percentiles
- asimetría (skewness)
- curtosis

Estas técnicas permitieron identificar distribuciones altamente asimétricas en variables financieras como presupuesto e ingresos.

2.2.2. Análisis bivariado

Para estudiar las relaciones entre variables se utilizaron:

- Matrices de correlación
- Diagramas de dispersión
- Análisis visual de tendencias

Las correlaciones permitieron evaluar el grado de asociación entre presupuesto, popularidad, valoraciones e ingresos en taquilla.

2.2.3. Análisis multivariado

Se aplicó el algoritmo K-Means para identificar agrupamientos de películas con características financieras similares. El análisis se realizó utilizando variables transformadas y permitió detectar patrones diferenciados y posibles observaciones atípicas dentro del mercado cinematográfico.

2.3. Detección de datos atípicos

La identificación de valores atípicos se realizó mediante diferentes enfoques estadísticos y gráficos:

2.3.1. Método IQR

Se utilizó el rango intercuartílico (IQR) para calcular límites inferiores y superiores de detección de outliers sobre las variables:

- presupuesto
- ingresos
- popularidad

2.3.2. Método Z-Score

Se aplicó el método Z-Score sobre variables previamente transformadas mediante logaritmos, debido a que estas presentaban distribuciones más cercanas a la normalidad. Se consideraron observaciones atípicas aquellas con valores absolutos superiores a 3.

2.3.3. Método K-Means

El algoritmo K-Means permitió detectar agrupamientos extremos y posibles anomalías multivariadas considerando simultáneamente:

- presupuesto
- ingresos
- Popularidad

2.4. Tratamiento de valores faltantes

El análisis de valores faltantes mostró que las variables financieras principales no presentaban datos ausentes después del proceso de limpieza. Por esta razón, no fue necesario aplicar métodos de imputación sobre las variables centrales del estudio.

Las variables con mayor porcentaje de valores faltantes corresponden principalmente a datos descriptivos, como:

- homepage
- tagline
- keywords

Estas variables fueron clasificadas principalmente bajo mecanismos MNAR y MAR, debido a que la ausencia de información dependía del contexto de producción o comercialización de las películas.

2.5. Transformación y escalamiento de variables

Debido a la fuerte asimetría presente en variables como presupuesto, ingresos y popularidad, se aplicaron diferentes técnicas de transformación y escalamiento.

2.5.1. Escalamiento

Se compararon los siguientes métodos:

- StandardScaler
- MinMaxScaler
- RobustScaler

El objetivo fue analizar el comportamiento de las variables bajo diferentes estrategias de normalización y evaluar su sensibilidad frente a valores extremos.

2.5.2. Transformaciones estadísticas

Para reducir la asimetría y aproximar las distribuciones a comportamientos normales se implementaron:

- transformación logarítmica
- transformación Box-Cox
- transformación Yeo-Johnson

La efectividad de cada transformación se evaluó mediante histogramas y coeficientes de asimetría.

2.6. Herramientas y librerías utilizadas

El proyecto fue desarrollado en Python utilizando herramientas especializadas en análisis y visualización de datos. Entre las principales librerías empleadas se encuentran:

- Pandas: manipulación y limpieza de datos.
- NumPy: operaciones numéricas y transformaciones.
- Matplotlib y Seaborn: visualización de datos.
- Scikit-learn: escalamiento, transformación y clustering.
- SciPy: análisis estadístico y transformaciones Box-Cox.
- WordCloud: generación de nubes de palabras.

El desarrollo del proyecto se realizó en un entorno Jupyter Notebook, permitiendo documentar y reproducir cada etapa del análisis.

3. Resultados y análisis

3.1. Análisis univariado




Figura 1: Distribución original de presupuesto, ingresos y popularidad.

Las distribuciones originales de presupuesto, ingresos y popularidad presentan una fuerte asimetría positiva, evidenciada por la concentración de observaciones en valores bajos y una cola extensa hacia valores altos. Este comportamiento indica que la mayoría de las películas poseen presupuestos e ingresos moderados, mientras que únicamente un pequeño grupo alcanza cifras extremadamente elevadas.

3.2. Estadística descriptiva

index	Media	Mediana	Desv_Std	Q1_25%	Q3_75%	Skewness	Kurtosis
budget	23932688.5	10000000.0	38198216.19	2200000.0	28000000.0	3.3	14.9
revenue	67151738.74	13300000.0	157043110.32	2000000.0	59790964.5	5.85	54.27
popularity	19.51	13.19	61.85	6.86	20.63	28.83	1089.99
vote_average	6.22	6.4	1.43	5.78	7.0	-2.17	7.77
averageRating	6.35	6.5	1.12	5.7	7.1	-0.78	1.29
runtime	108.98	105.0	22.48	94.0	120.0	1.16	2.92

Tabla 1: Tabla descriptiva.

Las variables financieras en la tabla 1 presentan diferencias importantes entre la media y la mediana, especialmente en ingresos y presupuesto, lo cual confirma la presencia de distribuciones sesgadas y valores extremos. La variable revenue presentó la mayor dispersión y curtosis, indicando la existencia de películas con recaudaciones extraordinariamente superiores al comportamiento promedio del conjunto de datos. En contraste, las variables de calificación mostraron distribuciones mucho más estables y concentradas alrededor de valores intermedios.

3.3. Relación entre variables




Figura 2: Matriz de correlación.

El análisis de correlación mostró que el presupuesto posee la relación más fuerte con los ingresos en taquilla ($r=0.74$), lo cual sugiere que las películas con mayores inversiones tienden a obtener mayores recaudaciones. La popularidad presentó una relación positiva pero débil con los ingresos ($r=0.23$), mientras que las valoraciones de los usuarios mostraron correlaciones bajas respecto al desempeño financiero. Adicionalmente, se observó una correlación moderada entre las variables de calificación `vote_average` y `averageRating` ($r=0.61$), indicando consistencia entre ambas métricas de evaluación. En conjunto, los resultados sugieren que el éxito financiero parece depender más de factores de producción y visibilidad comercial que de las calificaciones otorgadas por los espectadores.

3.4. Transformación de variables




Figura 3: Comparación de transformaciones para reducción de asimetría.

index	Skewness
budget_original	3.26
budget_log	-1.15
budget_boxcox	-0.04
budget_yeojohnson	-0.04
revenue_original	5.75
revenue_log	-0.8
revenue_boxcox	-0.04
revenue_yeojohnson	-0.04
popularity_original	28.37
popularity_log	-0.1
popularity_boxcox	0.01
popularity_yeojohnson	0.01

Tabla 2: Skewness antes y después de las transformaciones.

Las transformaciones aplicadas redujeron significativamente la asimetría presente en las variables financieras y de popularidad. Mientras las distribuciones originales presentaban skewness extremadamente elevados, las transformaciones Box-Cox y Yeo-Johnson lograron aproximar las variables a distribuciones cercanas a la normalidad. Esto permitió mejorar las condiciones estadísticas para posteriores análisis multivariados y detección de anomalías.

3.5. Comparación de métodos de escalamiento




Figura 4: Boxplots comparativos de escalamiento.

index	Media	Desv_Std	Min	Max
budget_original	24670573.54	38463254.43	1000.0	460000000.0
budget_std	0.0	1.0	-0.64	11.32
budget_minmax	0.05	0.08	0.0	1.0
budget_robust	0.54	1.41	-0.37	16.5
revenue_original	69487975.74	159035913.07	1000.0	2923706026.0
revenue_std	0.0	1.0	-0.44	17.95
revenue_minmax	0.02	0.05	0.0	1.0
revenue_robust	0.91	2.63	-0.24	48.18
popularity_original	20.04	63.3	0.0	2994.36
popularity_std	-0.0	1.0	-0.32	46.99
popularity_minmax	0.01	0.02	0.0	1.0
popularity_robust	0.49	4.69	-1.0	220.83

Tabla 3: Resumen estadístico de escalamiento.

Los métodos de escalamiento modificaron la escala de las variables sin alterar la estructura general de los datos ni la presencia de valores atípicos. StandardScaler centró las variables alrededor de media cero y desviación estándar unitaria, mientras que MinMaxScaler restringió los valores al intervalo entre 0 y 1. RobustScaler mostró un mejor comportamiento frente a valores extremos al utilizar la mediana y el rango intercuartílico, por lo que resulta especialmente adecuado para variables financieras altamente dispersas.

3.6. Detección de valores atípicos




Figura 5: Boxplots de detección de atípicos.

index	Q1	Q3	IQR	Limite_Inferior	Limite_Superior	Cantidad_Outliers	Porcentaje_Outliers
budget	22000000.0	280000000.0	258000000.0	-36500000.0	667000000.0	941.0	9.48
revenue	20000000.0	59790964.5	57790964.5	-84686446.75	146477411.25	1223.0	12.32
popularity	6.86	20.63	13.77	-13.8	41.29	653.0	6.58

Tabla 4: Outliers detectados mediante IQR.

El método IQR permitió identificar una proporción considerable de valores atípicos en las variables financieras. La variable revenue presentó el mayor porcentaje de observaciones extremas, lo cual evidencia que algunas películas obtienen ingresos excepcionalmente superiores al resto del mercado. Estos resultados reflejan la naturaleza altamente desigual de la industria cinematográfica, donde unas pocas producciones concentran gran parte de la recaudación global.

3.7. Detección de anomalías mediante Z-Score




Figura 6: Histogramas Z-Score.

index	Cantidad_Outliers	Porcentaje_Outliers
log_budget	182.0	1.94
log_revenue	71.0	0.76
log_popularity	39.0	0.42

Tabla 5: Outliers detectados con Z-Score.

La aplicación de Z-Score sobre las variables transformadas permitió detectar un número considerablemente menor de valores atípicos respecto al método IQR. Esto confirma que las transformaciones realizadas redujeron la influencia de distribuciones altamente sesgadas. La popularidad presentó muy pocos valores extremos después de la transformación logarítmica, indicando una mejora importante en la estabilidad estadística de la variable.

3.8. Análisis bivariado y anomalías




Figura 7: Scatterplots con outliers.

Los diagramas de dispersión evidencian una relación positiva entre presupuesto e ingresos, donde las películas con mayores inversiones tienden a obtener mayores recaudaciones. Sin embargo, también se identificaron películas con presupuestos relativamente altos y bajos ingresos, las cuales pueden considerarse fracasos comerciales. En el caso de la popularidad, se observaron algunas películas extremadamente visibles que alcanzaron ingresos muy superiores al promedio, reflejando el impacto del posicionamiento comercial sobre el desempeño financiero.

3.9. Agrupamiento mediante K-Means




Figura 8: Agrupamiento mediante K-Means

Los resultados obtenidos mediante K-Means permitieron identificar grupos de películas con comportamientos financieros diferenciados, incluyendo producciones de bajo presupuesto y bajo

ingreso, películas de rendimiento medio y producciones altamente exitosas tanto en popularidad como en recaudación. Además, algunos registros alejados de los grupos principales evidencian posibles anomalías multivariadas dentro del conjunto de datos.

4. Conclusiones

El presente trabajo permitió analizar la relación entre variables financieras, de popularidad y de valoración en películas mediante la aplicación de técnicas fundamentales de ciencia de datos. A partir del análisis exploratorio, se identificó que las variables presupuesto, ingresos y popularidad presentan distribuciones altamente asimétricas y con presencia significativa de valores atípicos, situación común en datos asociados a la industria cinematográfica.

Los resultados evidenciaron que el presupuesto posee la relación más fuerte con los ingresos en taquilla, sugiriendo que las películas con mayores niveles de inversión tienden a alcanzar mayores niveles de recaudación. Por otro lado, las valoraciones de los usuarios mostraron relaciones considerablemente más débiles con el desempeño financiero, indicando que el éxito económico no depende exclusivamente de la percepción crítica de los espectadores.

Las transformaciones estadísticas aplicadas, especialmente Box-Cox y Yeo-Johnson, permitieron reducir significativamente la asimetría de las variables, mejorando las condiciones para el análisis estadístico y la detección de anomalías. Asimismo, los métodos de detección de valores atípicos permitieron identificar películas con comportamientos financieros extremos, mientras que el uso de K-Means facilitó la identificación de grupos de películas con patrones similares de desempeño económico y popularidad.

Entre las principales limitaciones del estudio se encuentra la existencia de datos faltantes en variables textuales y descriptivas, además de que no se tuvo en cuenta el efecto de la inflación en la recaudación de películas antiguas; también está la ausencia de factores externos que influyen en el éxito comercial de una película, como estrategias de marketing, premios o contexto temporal de lanzamiento. Como trabajo futuro, sería interesante incorporar modelos predictivos de machine learning, análisis sobre reseñas de usuarios y variables relacionadas con plataformas de streaming o tendencias en redes sociales.

Referencias

1. Salazar, M. B. (2026). *Introducción a la ciencia de datos – Material del curso y sesiones prácticas* [Repositorio de GitHub]. GitHub. https://github.com/mariabda2/intro_data_2026?authuser=1
2. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Grisel, O., Blondel, M., et al. (2011). *Scikit-learn: aprendizaje automático en Python*. Journal of Machine Learning Research, 12, 2825–2830.
3. The pandas development team. (2024). *Documentación oficial de pandas*. <https://pandas.pydata.org/docs/>
4. Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., et al. (2020). *SciPy 1.0: algoritmos fundamentales para computación científica en Python*. Nature Methods, 17(3), 261–272. <https://doi.org/10.1038/s41592-019-0686-2>
5. Waskom, M. L. (2021). *Seaborn: visualización estadística de datos*. Journal of Open Source Software, 6(60), 3021. <https://doi.org/10.21105/joss.03021>
6. Python Software Foundation. (2024). *Python documentation*. <https://docs.python.org/3/>
7. SciPy Community. (2024). *SciPy documentation*. <https://docs.scipy.org/doc/scipy/>
8. NumPy Developers. (2024). *NumPy documentation*. NumPy. <https://numpy.org/doc/>
9. Hunter, J. D. (2007). *Matplotlib: A 2D graphics environment*. Computing in Science & Engineering, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>